

Dari Data Menuju Fungsi

Course:

Matrikulasi S3 Ilmu Komputer FILKOM UB

by:

Yuita Arum Sari, S.Kom., M.Kom., Ph.D.

yuita@ub.ac.id

Versi Dokumen:

Tanggal: 15; Bulan: September; Tahun: 2026

© Fakultas Ilmu Komputer, Universitas Brawijaya



filkom.ub.ac.id

© Fakultas Ilmu Komputer, Universitas Brawijaya

Dari $Ax = b$. Menuju $f(x) = ?$

Pertemuan 1

$$X\theta \approx y$$

- Fitur X sudah tersedia dalam bentuk tabel/matrix.
- Kita mencari parameter θ terbaik.
- Model berbentuk linear terhadap fitur.

Pertanyaan implisit: dari mana bentuk X berasal?

Pertemuan 2

$$f(x) \approx y$$

- Kita HANYA memiliki titik data (x_i, y_i) .
- Kita perlu MEMBANGUN fungsi $f(x)$ itu sendiri.
- Bentuk fungsi bisa linear, polinomial, atau piecewise.

Spoiler: di akhir, ini akan kembali ke $X\beta \approx y$.

MATEMATIKA → REPRESENTASI → MODEL → LOSS → PREDIKSI

Jika Hanya Ada Titik Data, Bagaimana Membangun Fungsi?

$$(x_1, y_1), (x_2, y_2), \dots, (x_n, y_n) \rightarrow f(x) = ?$$

Ini adalah pertanyaan inti dalam *supervised learning* dan regresi: dari observasi terbatas, bagaimana membangun fungsi yang berguna pada data baru?

?

Apakah f harus MELEWATI setiap titik data secara eksak?

?


Atau cukup MENDEKATI data secara keseluruhan?

?

Bagaimana jika data mengandung noise / pengukuran salah?

Satu Benang Merah: Dari Data ke Model AI

Intinya selalu sama: data direpresentasikan $\rightarrow$ fungsi menghasilkan prediksi $\rightarrow$ error diukur $\rightarrow$ parameter diperbaiki.



Matematika memberi bahasa untuk setiap tahap.

AI/ML terutama menambahkan proses BELAJAR: parameter θ tidak ditentukan manual, tetapi dicari dari data.

CONTOH CITRA

Resize citra dengan bilinear interpolation

x = koordinat baru $\rightarrow \phi(x) = 4$ piksel tetangga
 f = bobot jarak $\rightarrow \hat{y}$ = intensitas piksel baru

Contoh: 10, 20, 30, 40 $\rightarrow$ titik tengah $\rightarrow \hat{y} = 25$

CONTOH TEKS / ML

Klasifikasi sentimen dari sebuah kalimat

x = "pelayanannya bagus" $\rightarrow \phi(x)$ = embedding
 f_{θ} = classifier $\rightarrow \hat{y}$ = probabilitas positif

Jika label y = positif, loss mengukur seberapa jauh $\hat{y}$ dari target.

1. Interpolation vs Approximation

Dua tujuan berbeda dalam membangun fungsi dari data

Titik Data: Bahan Baku Setiap Fungsi

Kita mulai dari sekumpulan pasangan (x,y) hasil pengamatan atau pengukuran.

$$(x_1, y_1), (x_2, y_2), \dots, (x_n, y_n)$$

Contoh Sumber Data

- Sensor: suhu, tekanan, posisi GPS pada waktu tertentu.
- Citra: nilai piksel pada koordinat tertentu.
- Eksperimen: hasil pengukuran pada berbagai kondisi.
- Dataset ML: pasangan fitur dan label.

Yang Ingin Kita Cari

- Sebuah fungsi $f(x)$ yang dapat memprediksi nilai y pada TITIK BARU x yang belum diamati.
- $f(x)$ bisa berupa garis lurus, kurva polinomial, atau gabungan potongan kurva (*piecewise*).
- **Cara memilih $f(x)$ inilah yang membedakan *interpolation* dan *approximation*.**

Interpolation: Fungsi Melewati Setiap Titik Data


Tujuannya bukan mencari tren, tetapi merekonstruksi nilai di antara data yang sudah diketahui.

SYARAT UTAMA

$$f(x_i) = y_i \text{ untuk semua } i$$

→ error pada titik data = 0

INTUISI VISUAL



Kapan interpolasi masuk akal?

1

DATA DIPERCAYA

Titik yang diketahui dianggap valid/cukup akurat.

2

NILAI DI ANTARA

Kita ingin menaksir x baru yang masih berada di dalam rentang data.

3

REKONSTRUKSI

Fokusnya mengisi nilai yang belum tersedia, bukan mempelajari tren umum.

CONTOH NYATA

Sensor

08.00: 24°C · 10.00: 28°C

Estimasi 09.00 → 26°C

Citra

4 piksel tetangga diketahui

Bilinear → estimasi piksel baru

Animasi

Posisi frame awal & akhir

Interpolasi → posisi antar-frame

Ingat: INTERPOLASI = "harus melewati titik yang diketahui". Jika data noisy dan ingin menangkap pola umum → gunakan approximation/regression.

Interpolation: Contoh penerapan CLAHE pada Citra

Tile Equalization (No Interpolation)



CLAHE Final (With Interpolation)




Approximation/Regression: Fungsi Menangkap Pola Data

Fungsi tidak wajib melewati semua titik. Yang dicari adalah model yang membuat kesalahan keseluruhan sekecil mungkin.

IDE MATEMATIS

$$f(x_i) \approx y_i$$
$$\min \sum (y_i - f(x_i))^2$$

INTUISI VISUAL



Mengapa tidak dipaksa melewati semua titik?

1

ADA NOISE

Pengukuran bisa berfluktuasi. Memaksa semua titik justru dapat mengikuti noise.

2

CARI POLA UMUM

Model merangkum hubungan $x \rightarrow y$, bukan menghafal setiap observasi.

3

PREDIKSI DATA BARU

Tujuan akhirnya adalah bekerja baik pada data yang belum pernah dilihat.

CONTOH NYATA

Regresi eksperimen

Jam belajar $\rightarrow$ nilai ujian

Cari garis yang meminimalkan total residual

Sensor noisy

24.1, 25.8, 24.9, 26.2, ...

Fit/smoothing $\rightarrow$ estimasi tren suhu

Machine Learning

fitur $x \rightarrow$ model $f_{\theta}(x) \rightarrow \hat{y}$

Training mencari θ yang meminimalkan loss


Benang merah ke AI/ML: approximation = memilih fungsi f_{θ} dan mencari parameter θ agar loss kecil serta mampu melakukan generalisasi.

Data Sama, Dua Fungsi Berbeda

Interpolasi

Fungsi dipaksa MELEWATI semua titik data.

$$f(x_i) = y_i \text{ untuk semua } i$$



Contoh Nyata



Sensor

Mengisi nilai yang hilang di antara dua pembacaan.



Citra

Estimasi nilai piksel baru saat memperbesar gambar (resize).



Animasi

Interpolasi posisi antar-frame kunci.




Cocok ketika:

Data dipercaya akurat dan kita ingin mengisi nilai DI ANTARA titik data yang diketahui.


Aproksimasi / Regresi

Fungsi MENDEKATI data dengan meminimalkan total error.

$$\min_{\theta} \sum_i (y_i - f(x_i; \theta))^2$$



Contoh Nyata




Eksperimen

Regresi linear/polinomial pada data yang berisik (noisy).



Sensor

Smoothing sinyal untuk mengurangi noise pengukuran.



Machine Learning

Hampir semua model prediktif adalah aproksimasi fungsi.



Cocok ketika:

Data mengandung noise atau ketidakpastian, dan kita ingin menemukan pola umum.

Memilih Interpolation vs Approximation

Pertimbangan	Interpolation	Approximation
Kualitas data	Bersih, akurat, tanpa noise	Ada noise/ketidakpastian
Jumlah titik	Sedikit → sedang	Banyak (n besar)
Tujuan	Rekonstruksi nilai di antara data	Menangkap tren/pola umum
Risiko utama	Osilasi liar (Runge's phenomenon) – semakin tinggi derajat polinomial interpolasi, kurva tidak selalu semakin baik	Underfitting/overfitting
Contoh domain	Grafik komputer, tabel numerik	Machine learning, statistik

Jika nilai antar-titik dianggap valid dan ingin direkonstruksi → interpolation. Jika ingin menangkap pola umum dari data noisy → approximation. Validasi tetap diperlukan.

2. Metode Interpolasi

Linear, Lagrange, spline, dan bahaya Runge's phenomenon

Linear Interpolation: Menghubungkan Dua Titik

Metode interpolasi paling sederhana, menarik garis lurus antar dua titik terdekat.

Rumus **interpolasi linear**:

$$f(x) = y_0 + \frac{y_1 - y_0}{x_1 - x_0} (x - x_0)$$


dengan:

(x_0, y_0) = titik awal

(x_1, y_1) = titik akhir

x = posisi yang ingin dicari

$f(x)$ = **nilai perkiraan di antara kedua titik**




- Diberikan dua titik (x_0, y_0) dan (x_1, y_1) , tarik garis lurus di antaranya.
- Nilai $f(x)$ untuk $x_0 < x < x_1$ dihitung proporsional terhadap jaraknya dari kedua titik.
- Sederhana, cepat, tapi hanya akurat jika data cukup rapat/cenderung linear di sekitar titik *query*.

Linear Interpolation: Bukan Sekadar Substitusi Rumus

Lihat interpolasi sebagai weighted combination: posisi x menentukan seberapa besar kontribusi setiap titik.

1 GEOMETRI MASALAH

Diketahui $P_0=(1,2)$, $P_1=(3,8)$. Cari $f(2)$.



$x=2$ tepat 50% di antara x_0 dan x_1

2 DARI POSISI → BOBOT

Parameter posisi (normalized distance)

$$t = (x - x_0)/(x_1 - x_0) = (2-1)/(3-1) = 0.5$$

3 BENTUK WEIGHTED COMBINATION

$$f(x) = (1 - t)y_0 + ty_1$$

$$f(2) = 0.5(2) + 0.5(8)$$

$$f(2) = 5$$

$x=2$ berada tepat di tengah → kedua titik mendapat bobot sama, 50% : 50%.

Interpolasi Polinomial

NEWTON

Divided differences
mudah diperluas


LAGRANGE

Basis polynomial
langsung dari titik

SPLINE

Fungsi lokal per interval
lebih stabil secara lokal

semua metode membangun fungsi yang melewati data diketahui; yang berbeda adalah cara fungsi tersebut dikonstruksi.



Interpolasi Polinomial Newton

- Diketahui: n titik $(x_1, y_1), (x_2, y_2), \dots, (x_n, y_n)$ ($y_i = f(x_i), i=1,2,\dots,n$)
- Ditanya: $f_n(x) = a_0 + a_1x + a_2x^2 + \dots + a_nx^n$ yang melewati n titik tersebut.

$$f_n(x) = b_0 + b_1(x - x_0) + \dots + b_n(x - x_0)(x - x_1) \dots (x - x_{n-1})$$

$$b_0 = f(x_0)$$

$$b_1 = f[x_1, x_0]$$

$$b_2 = f[x_2, x_1, x_0]$$

.

.

.

$$b_n = f[x_n, x_{n-1}, \dots, x_1, x_0]$$

$$f[x_i, x_j] = \frac{f(x_i) - f(x_j)}{x_i - x_j}$$

$$f[x_i, x_j, x_k] = \frac{f[x_i, x_j] - f[x_j, x_k]}{x_i - x_k}$$

$$f[x_n, x_{n-1}, \dots, x_1, x_0] = \frac{f[x_n, x_{n-1}, \dots, x_1] - f[x_{n-1}, x_{n-2}, \dots, x_0]}{x_n - x_0}$$

Contoh Interpolasi Polinomial Newton (1/2)

1 DATA

$$f(x) = \ln x$$

i	x	ln(x)
0	1	0
1	4	1.386294
2	6	1.791759
3	5	1.609438

Target: estimasi ln 2

$$x = 2$$

2 ORDE 1 · SLOPE

$$f[x_i, x_j] = (f_i - f_j)/(x_i - x_j)$$

$$f[x_1, x_0]$$

$$(1.386294 - 0)/(4 - 1) \\ = 0.4620981$$

$$f[x_2, x_1]$$

$$(1.791759 - 1.386294)/(6 - 4) \\ = 0.2027326$$

$$f[x_3, x_2]$$

$$(1.609438 - 1.791759)/(5 - 6) \\ = 0.1823216$$

3 ORDE 2 · CURVATURE

$$f[a, b, c] = (f[a, b] - f[b, c])/(a - c)$$

$$f[x_2, x_1, x_0]$$

$$(0.2027326 - 0.4620981) / (6 - 1) \\ = -0.05187311$$

$$f[x_3, x_2, x_1]$$

$$(0.1823216 - 0.2027326) / (5 - 4) \\ = -0.02041100$$

Perubahan slope →
kelengkungan

4 ORDE 3 + ERROR

$$f[a, b, c, d] \\ = (f[a, b, c] - f[b, c, d])/(a - d)$$

$$f[x_3, x_2, x_1, x_0] \\ = [-0.02041100 - (-0.05187311)] / (5 - 1) \\ = 0.007865529$$

Estimasi galat orde ke-2:

$$R_2 = f[x_3, x_2, x_1, x_0] / (2 - 1)(2 - 4)(2 - 6)$$

$$R_2 \approx 0.0629242$$

Contoh Interpolasi Polinomial Newton (2/2)

Data → divided differences → koefisien → polinomial → estimasi $f(2)$.

$$f_3(x) = b_0 + b_1(x - x_0) + b_2(x - x_0)(x - x_1) + b_3(x - x_0)(x - x_1)(x - x_2)$$

Data: (1,0), (4,1.386294), (6,1.791759), (5,1.609438)

1 DIVIDED DIFFERENCES

Orde 1 $f[x_1, x_0] = (1.386294 - 0) / (4 - 1) = 0.4620981$

$$f[x_2, x_1] = (1.791759 - 1.386294) / (6 - 4) = 0.2027326$$

$$f[x_3, x_2] = (1.609438 - 1.791759) / (5 - 6) = 0.1823216$$

Orde 2 $f[x_2, x_1, x_0] = (0.2027326 - 0.4620981) / (6 - 1) = -0.05187311$

$$f[x_3, x_2, x_1] = (0.1823216 - 0.2027326) / (5 - 4) = -0.02041100$$

Orde 3 $f[x_3, x_2, x_1, x_0] = (-0.02041100 - (-0.05187311)) / (5 - 1) = 0.007865529$

2 AMBIL KOEFISIEN DIAGONAL

$$b_0 = f(x_0) = 0$$

$$b_1 = f[x_1, x_0] = 0.4620981$$

$$b_2 = f[x_2, x_1, x_0] = -0.05187311$$

$$b_3 = f[x_3, x_2, x_1, x_0] = 0.007865529$$

→ koefisien langsung masuk ke bentuk Newton

$$f_3(x) = 0 + 0.4620981(x - 1) - 0.05187311(x - 1)(x - 4) + 0.007865529(x - 1)(x - 4)(x - 6)$$

$$f_3(2) = 0.6287686$$

hitung divided differences → ambil diagonal sebagai b_0, b_1, b_2, b_3 → substitusikan ke polinomial Newton.

Interpolasi Lagrange

- Nama diambil dari penemunya Joseph Louis Lagrange (Perancis)
- Bentuk umum derajat $\leq n$ untuk $(n+1)$ titik berbeda :

$$p_n(x) = \sum_{i=0}^n y_i L_i(x) = y_0 L_0(x) + y_1 L_1(x) + \dots + y_n L_n(x)$$

$$L_i(x) = \prod_{\substack{j=0 \\ j \neq i}}^n \frac{(x - x_j)}{(x_i - x_j)} = \frac{(x - x_0)(x - x_1) \dots (x - x_{i-1})(x - x_{i+1}) \dots (x - x_n)}{(x_i - x_0)(x_i - x_1) \dots (x_i - x_{i-1})(x_i - x_{i+1}) \dots (x_i - x_n)}$$

Interpolasi Lagrange

Diketahui tiga titik → hitung tiga basis L_0, L_1, L_2 → gabungkan kontribusinya untuk mencari $p_2(3.5)$.

1 DATA

X	1	4	6
Y	1.5709	1.5727	1.5751

TARGET

$x = 3.5$
cari $p_2(3.5)$

$$p_2(x) = L_0(x)y_0 + L_1(x)y_1 + L_2(x)y_2$$
$$L_i(x) = \prod_{j \neq i} (x - x_j) / (x_i - x_j)$$

2 HITUNG BOBOT / BASIS PADA $x = 3.5$

$$L_0(3.5) = [(3.5-4)(3.5-6)] / [(1-4)(1-6)] = 0.083333$$

$$L_1(3.5) = [(3.5-1)(3.5-6)] / [(4-1)(4-6)] = 1.0417$$

$$L_2(3.5) = [(3.5-1)(3.5-4)] / [(6-1)(6-4)] = -0.12500$$

3 GABUNGAN KONTRIBUSI

$$p_2(3.5) = (0.083333)(1.5709) + (1.0417)(1.5727) + (-0.12500)(1.5751)$$

$$p_2(3.5) \approx 1.5723$$


setiap titik memberi kontribusi $y_i L_i(x)$; jumlah seluruh kontribusi menghasilkan nilai interpolasi.

Runge's Phenomenon: Bahaya Derajat Tinggi

- Polinomial interpolasi derajat tinggi dapat bersilasi liar di dekat tepi domain.
- Menambah titik data (menaikkan derajat) justru memperburuk osilasi di tepi.




Runge's Phenomenon



— Fungsi asli $f(x)$
— Polinomial derajat tinggi
• Titik data




Spline Interpolation




— Fungsi asli $f(x)$
— Spline (piecewise polinomial derajat rendah)
• Titik data


1 polinomial global derajat tinggi



Osilasi besar di tepi domain



Beberapa polinomial lokal derajat rendah (Spline)




Interpolasi Spline Linier: Pilih Segmen, Hitung Slope, Estimasi Nilai

Spline linier menghubungkan titik-titik dengan garis lokal. Untuk x tertentu, cukup gunakan interval yang memuat x tersebut.

1 IDE DASAR

$$f_i(x) = f(x_i) + m_i(x - x_i)$$

$$m_i = [f(x_{i+1}) - f(x_i)] / (x_{i+1} - x_i)$$



Gunakan hanya segmen [4.5, 7]

2 PILIH INTERVAL

	Data			
x	3.0	4.5	7.0	9.0
f(x)	2.5	1.0	2.5	0.5

Karena $x = 5$:
 $4.5 \leq 5 \leq 7$

Titik $x=3$ dan $x=9$ tidak diperlukan untuk menghitung $f(5)$.

3 HITUNG PADA SEGMENT [4.5, 7]

Slope segmen:

$$m = (2.5 - 1.0) / (7.0 - 4.5) = 0.60$$

Persamaan lokal:

$$f(x) = 1.0 + 0.60(x - 4.5)$$

Substitusi $x=5$:

$$f(5) = 1 + 0.60(0.5) = 1.3$$


HASIL: $f(5) = 1.3$

banyak titik → dibagi menjadi beberapa interval → setiap interval punya garis sendiri → pilih interval target → interpolasi linear lokal.

Spline: Bukan Satu Kurva Besar, tetapi Beberapa Fungsi Lokal

Setiap interval memiliki fungsi sendiri; fungsi-fungsi itu bertemu pada titik data (knot).

1 SATU FUNGSI UNTUK SETIAP INTERVAL



2 APA YANG TERJADI DI KNOT?

Minimal: kedua potongan bertemu pada nilai yang sama.

$$S_0(x_1) = S_1(x_1)$$

Pada cubic spline, biasanya dibuat lebih halus lagi:

$$S_0'(x_1) = S_1'(x_1)$$

$$S_0''(x_1) = S_1''(x_1)$$

→ nilai, kemiringan, dan kelengkungan menyambung.

Linear Spline vs Cubic Spline

Keduanya piecewise: yang berbeda adalah bentuk fungsi pada SETIAP interval dan tingkat kehalusan di knot.

LINEAR SPLINE

$$S_i(x) = a_i + b_i x$$




Menyambung, tetapi arah dapat berubah tajam di knot

Derajat 1

S dan titik bertemu

CUBIC SPLINE

$$S_i(x) = a_i + b_i x + c_i x^2 + d_i x^3$$



Menyambung halus: arah dan kelengkungan dibuat kontinu

Derajat 3

S, S', S'' kontinu

3. Case A: *Missing Sensor Data*

Mengisi data time-series yang hilang dengan interpolasi

Sensor Suhu Kehilangan Satu Pembacaan


Kasus umum dalam IoT, monitoring lingkungan, dan data time-series.

t (jam)	0	1	2	3	4	5
Suhu (°C)	20	21	23	?	26	25

- Pembacaan sensor pada $t=3$ HILANG (gangguan koneksi, baterai lemah, dsb).
- Kita ingin ESTIMASI nilai suhu pada $t=3$ menggunakan data di sekitarnya.
- **Dua kandidat: LINEAR interpolation (cepat, sederhana) dan SPLINE interpolation (lebih halus, mempertimbangkan tren).**



Mengisi Data dengan Interpolasi Linear



Gunakan titik tetangga: (t=2, 23°C) dan (t=4, 26°C)

$$T(3) = 23 + (26 - 23)/(4 - 2) \times (3 - 2)$$

$$T(3) = 23 + 1,5 \times 1 = 24,5^{\circ}\text{C}$$

$$T(3) \approx 24,5^{\circ}\text{C}$$


Linear interpolation mengasumsikan kenaikan suhu KONSTAN di antara t=2 dan t=4. Ini masuk akal jika tren suhu relatif linear pada rentang pendek.

Mengisi Data Hilang: Linear vs Spline

Pertanyaan: suhu pada $t=3$ hilang. Apakah cukup memakai dua tetangga terdekat, atau mengikuti tren di sekitarnya?

t (jam)	0	1	2	3	4	5
	20°	21°	23°	?	26°	25°

LIHAT BENTUK DATA, BUKAN HANYA DUA TITIK



KENAPA HASILNYA BISA BERBEDA?

LINEAR

Hanya melihat $t=2$ dan $t=4$.

23°C ————— 26°C

$T(3)=24.5^{\circ}\text{C}$

SPLINE

Memakai beberapa titik untuk membentuk kurva lokal yang halus.

$T(3)\approx 24.3^{\circ}\text{C}^*$


linear menghubungkan dua tetangga terdekat; spline membentuk kurva piecewise dari beberapa titik sehingga dapat mengikuti perubahan tren.

Interpolation = Salah Satu Fondasi Data Imputation

Nilai yang hilang dapat diperkirakan dari struktur data—tetapi metode imputasi tidak selalu sama dengan interpolasi.



TIME-SERIES / IoT



Interpolasi mengisi nilai hilang berdasarkan urutan waktu/koordinat.

`pandas interpolate()`

PREPROCESSING ML

KNN

Simple

≠

INTERPOLASI

KNN mencari sampel mirip;
SimpleImputer memakai statistik.
Interpolasi memakai posisi/urutan data.

SIGNAL PROCESSING




Resampling audio/sensor membutuhkan interpolasi untuk memperkirakan sampel pada posisi waktu baru.

new sample points

4. Case B: *Image Resizing*

Mengestimasi piksel baru dengan interpolasi 2D

Memperbesar Citra: Piksel Baru harus Diestimasi



Intuisi

Piksel baru tidak diukur langsung oleh sensor, tetapi dihitung dari piksel tetangganya agar transisi warna/keabuan tetap halus.

Contoh Metode Interpolasi (hasil visual)

Nearest Neighbor



Cepat, hasil cenderung kotak-kotak.

Bilinear



Lebih halus dibanding nearest.

Bicubic



Lebih halus, detail lebih baik.

Lanczos




Hasil tajam, menjaga detail.


Nearest Neighbor: Salin dari Tetangga Terdekat

1 Ide Dasar

Untuk setiap koordinat piksel baru, ambil nilai piksel **ASLI** yang posisinya paling dekat.



2 Contoh pada Citra



Citra asli
(2 × 2)

Diperbesar dengan
Nearest Neighbor
(tampak kotak-kotak)

3 Ilustrasi Numerik (2×2 → 4×4)

Citra asli (2 × 2)

50	80
200	120


Nearest
Neighbor

Citra hasil (4 × 4)

50	50	80	80
50	50	80	80
200	200	120	120
200	120	120	120

Setiap 2×2 blok = salinan 1 piksel sumber
(nilai terdekat)

4 Hasil dan Karakteristik



Nearest Neighbor


Cepat, tetapi tampak kotak-kotak

- ✓ Sangat cepat (komputasi ringan).
- ✓ Tidak ada perhitungan pembobotan.
- ✓ Cocok untuk aplikasi real-time.
- ✗ Hasil tampak "kotak-kotak" (blocky/pixelated).
- ✗ Kurang halus dibanding metode lain (bilinear, bicubic, lanczos).



Intuisi

Bayangkan gambar diperbesar seperti mozaik: setiap piksel baru hanya menyalin nilai piksel lama terdekat, sehingga blok warna menjadi lebih besar.



1 piksel → diperbesar
menjadi beberapa piksel dengan nilai sama



Kapan Digunakan?

Cocok saat kecepatan lebih penting daripada kualitas visual, misalnya pada aplikasi embedded, real-time video, atau pratinjau cepat.


Bilinear Interpolation: Rata-rata Berbobot 4 Tetangga

Setup

Blok 2x2 piksel:


$P_{01}=30$	$P_{11}=40$
$P_{00}=10$	$P_{10}=20$

Cari nilai piksel baru di TITIK TENGAH ($x=0,5, y=0,5$):



Di titik tengah, keempat bobot sama besar (0,25) sehingga hasilnya adalah RATA-RATA SEDERHANA. Di titik lain, bobot berubah sesuai jarak.

Bicubic Interpolation: Melibatkan 16 Tetangga



Sering lebih halus daripada nearest/bilinear, tetapi tidak selalu “terbaik”: hasil bergantung pada jenis citra, skala pembesaran, dan tujuan analisis.


Nearest vs Bilinear vs Bicubic

Aspek	Nearest Neighbor	Bilinear	Bicubic
Jumlah tetangga	1	4 (2×2)	16 (4×4)
Kecepatan	Tercepat	Sedang	Paling lambat
Kualitas visual	Blocky / kotak-kotak	Cukup halus, sedikit blur	Paling halus
Kompleksitas	O(1) per piksel	O(4) per piksel	O(16) per piksel
Cocok untuk	Preview cepat, pixel art	Kebutuhan umum	Cetak, kualitas tinggi

Trade-off universal: kualitas lebih tinggi = lebih banyak tetangga = lebih mahal secara komputasi

Interpolasi 2D di Balik Computer Vision Modern

Ide matematisnya sama: menentukan nilai piksel pada koordinat baru. Yang berubah adalah apakah aturannya tetap atau dipelajari dari data.



Interpolasi klasik: kernel ditentukan.. CV modern: sebagian operasi tetap memakai interpolasi, sebagian lain BELAJAR cara menghasilkan piksel/fitur baru.

Interpolasi di Ruang Fitur: Dari Data ke AI/ML

Yang diinterpolasi bukan kalimatnya, tetapi **REPRESENTASI NUMERIK** yang dihasilkan encoder.



CONTOH: LATENT / FEATURE-SPACE AUGMENTATION

A: "cemas ujian"

$z_A = [0,8; 0,2]$

B: "takut sidang"

$z_B = [0,4; 0,6]$



$$z_{mix} = 0,7z_A + 0,3z_B = [0,68; 0,32]$$

Hasilnya = VEKTOR sintetis baru untuk training, bukan kalimat baru.

LALU UNTUK APA?

1 MIX

Buat titik baru di antara dua representasi yang relevan.

2 TRAIN

Masukkan z_{mix} ke classifier / model sebagai sampel tambahan.

3 LEARN

Dorong model belajar ruang keputusan yang lebih halus dan robust.

Contoh konsep: latent-space augmentation / mixup-like training

Interpolasi tetap menghitung "nilai di antara dua titik"; pada AI/ML titik tersebut dapat berupa VEKTOR FITUR, bukan koordinat fisik.

Terima Kasih

Yuita Arum Sari, S.Kom., M.Kom., Ph.D.
yuita@ub.ac.id

Versi Dokumen:

Tanggal: 15; Bulan: September; Tahun: 2026

© Fakultas Ilmu Komputer, Universitas Brawijaya



filkom.ub.ac.id